

ANALIZA ROZWIĄZAŃ ODSZUMIANIA B-SKANÓW OCT SIATKÓWKI OKA LUDZKIEGO

inż. Szymon Murawski

promotor: dr inż. Tomasz Marciniak

POLITECHNIKA POZNAŃSKA

WYDZIAŁ AUTOMATYKI, ROBOTYKI I ELEKTROTECHNIKI

INSTYTUT AUTOMATYKI I ROBOTYKI

ZAKŁAD UKŁADÓW ELEKTRONICZNYCH I PRZETWARZANIA SYGNAŁÓW

09.07.2024

Zakres pracy magisterskiej

- Analiza technik odsumiania obrazów w optycznej tomografii koherencyjnej
- Przygotowanie oprogramowania do odsumiania B-skanów OCT różnych baz danych
- Ocena skuteczności i czasochłonności obliczeniowej odsumiania dla segmentacji warstw siatkówki



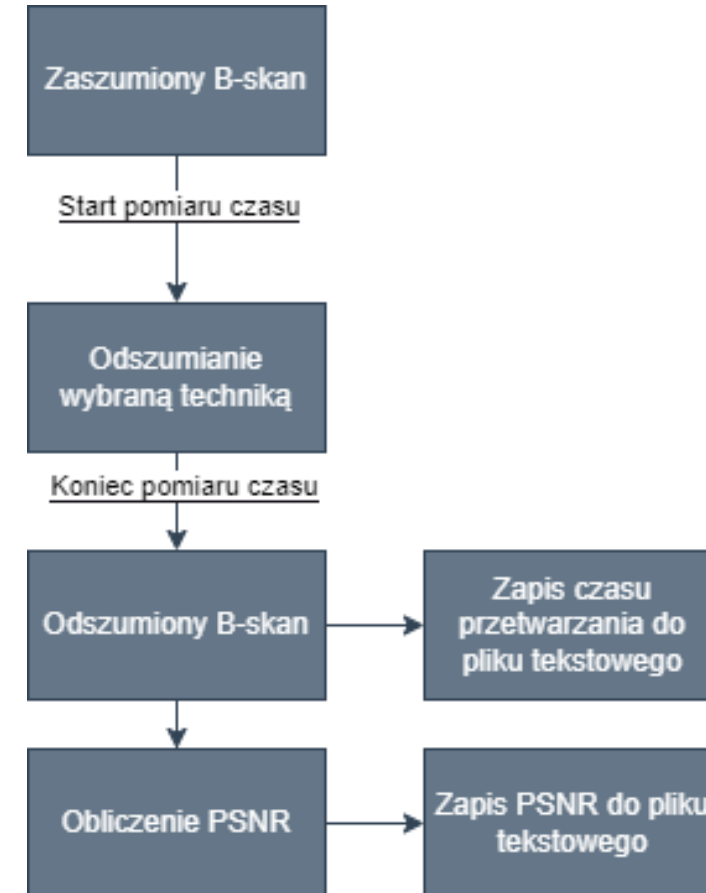


Analiza technik odszumiania

Nazwa metody		Źródło	Zastosowane metryki
•	Filtr uśredniający	Jadwiga Rogowska, Mark E Brezinski. <i>Image processing techniques for noise removal, enhancement and segmentation of cartilage OCT images</i>	• subiektywna ocena jakości segmentacji
•	Filtr medianowy		
•	RKT		
•	Anizotropowy filtr dyfuzyjny	Rui Bernardes, Cristina Maduro, Pedro Serranho, Aderito Araújo, Silvia Barbeiro, Jose Cunha-Vaz. <i>Improved adaptive complex diffusion despeckling filter</i>	• MSE • PSNR • ENL • CNR
•	Transformata zafalowaniowa	Wajiha Habib, Adil Masood Siddiqui, Imran Touqir. <i>Wavelet Based Despeckling of Multiframe Optical Coherence Tomography Data Using Similarity Measure and Anisotropic Diffusion Filterin</i>	• PSNR • współczynnik korelacji Pearson’a
•	Minimalizacja prawdopodobieństwa warunkowego	Alexander Wong, Akshaya Mishra , Kostadinka Bizheva , David A. Clausi. <i>General Bayesian estimation for speckle noise reduction in optical coherence tomography retinal imagery</i>	• PSNR • CNR • ENL • wsp. zachowania krawędzi • czasochłonność
•	DnCNN, FFDNet	Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, Lei Zhang. <i>Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising</i> Kai Zhang, Wangmeng Zuo, Lei Zhang. <i>FFDNet: Toward a Fast and Flexible Solution for CNN based Image Denoising</i>	• PSNR • SSIM • czasochłonność
•	ADNet	Chunwei Tian, Yong Xu, Zuoyong, Wangmeng Zuo, Lunke Fei, Hong Liu. <i>Attention-guided CNN for image denoising</i>	• PSNR • czasochłonność
•	DeSpecNet	Fei Shi, Ning Cai, Yunbo Gu, Dianlin Hu, Yuhui Ma, Yang Chen, Xinjian Chen. <i>DeSpecNet: a CNN-based Method for Speckle Reduction in Retinal Optical Coherence Tomography Images</i>	• PSNR • CNR • ENL • wsp. zachowania krawędzi

Przygotowane oprogramowanie do odszumiania

Wybrane metody odszumiania:

- filtr uśredniający i medianowy (Matlab)
- DnCNN (Matlab)
- FFDNet (Matlab)
- ADNet (Python)




Bazy obrazów

Baza CAVRI-A


- 7050 B-skanów z danymi dotyczącymi segmentacji
- Autorzy: Agnieszka Stankiewicz, Tomasz Marciniak

Baza OCTID

- 495 B-skanów, 19 z danymi dotyczącymi segmentacji
- Źródło: Peyman Gholami, Priyanka Roy, Mohana Kuppuswamy Parthasarathy, Vasudevan Lakshminarayanan. *OCTID: Optical Coherence Tomography Image Database*



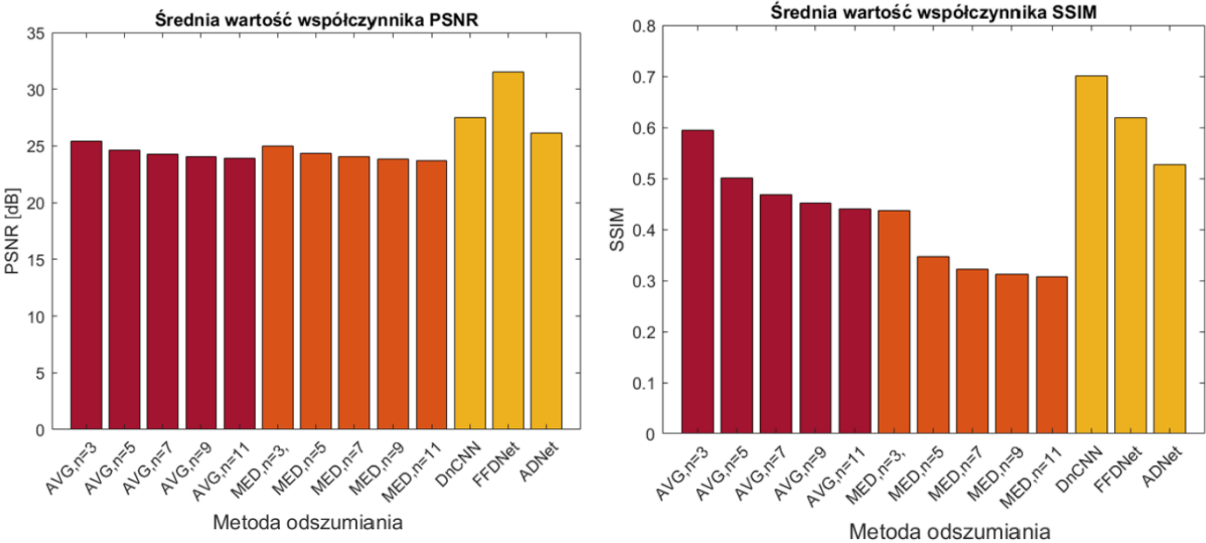
CAVRI-A



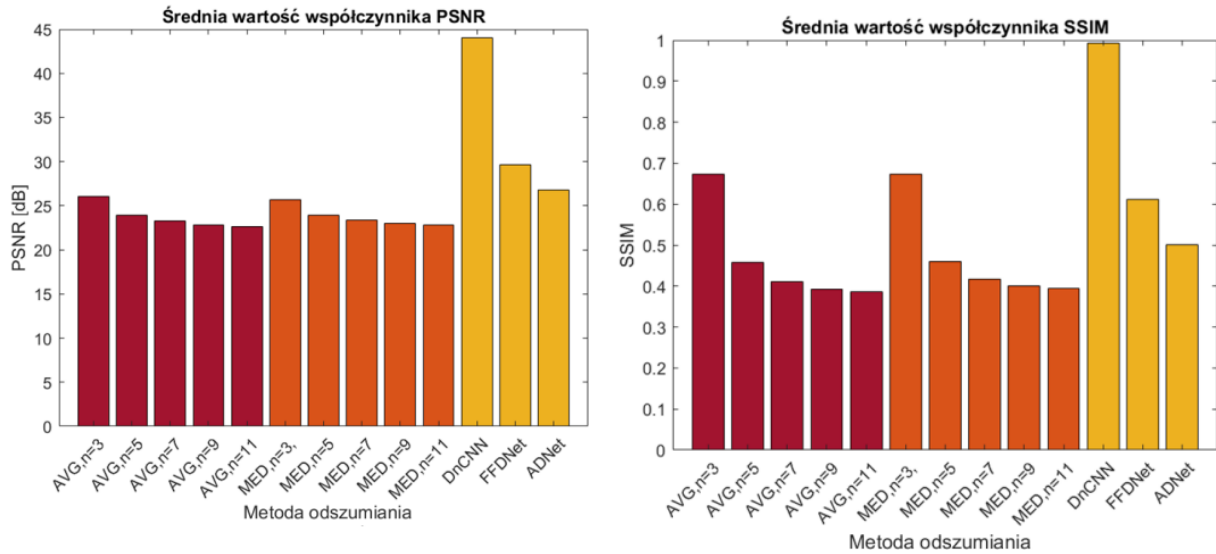
OCTID

Ocena parametryczna odszumiania – PSNR, SSIM

CAVRI-A




OCTID




Nazwa metody	Czas dla bazy CAVRI-A [s]	Czas dla bazy OCTID [s]
Filtr uśr. n=3	0.00065394	0.00075269
Filtr uśr. n=5	0.00067575	0.00087709
Filtr uśr. n=7	0.00082889	0.0011128
Filtr uśr. n=9	0.0008324	0.0010038
Filtr uśr. n=11	0.0010275	0.011922
Filtr med. n=3	0.00064481	0.00063959
Filtr med. n=5	0.0006741	0.00071115
Filtr med. n=7	0.0028972	0.0019589
Filtr med. n=9	0.0028171	0.0018955
Filtr med. n=11	0.0032264	0.0057853
Sieć DnCNN	0.98832	1.41089
Sieć FFDNet	5.1386	6.96093
Sieć ADNet	1.746	2.2650

Przykładowe rezultaty odszumionych B-skanów z bazy CAVRI-A




Przykładowe rezultaty odszumionych B-skanów z bazy OCTID


Bez odszumiania



Filtr medianowy, n=11




Sieć ADNet




Segmentacja siatkówki

Segmentacja w oparciu o oprogramowanie **Caserel** [1]. Kod programu przygotowane w środowisku Matlab




NFL: Nerve Fiber Layer
GCL: Ganglion Cell Layer
IPL: Inner Plexiform Layer
INL: Inner Nuclear Layer
OPL: Outer Plexiform Layer

ONL: Outer Nuclear Layer
IS: Inner Segment
OS: Outer Segment
RPE: Retinal Pigment Epithelium






[1] Stephanie J. Chiu, Xiao T. Li, Peter Nicholas, Cynthia A. Toth, Joseph A. Izatt, Sina Farsiu. Automatic segmentation of seven retinal layers in SDOCT images congruent with expert manual segmentation. Optics Express vol.18 no.18, 30.08.2010

Przykładowe rezultaty segmentacji dla bazy CAVRI-A

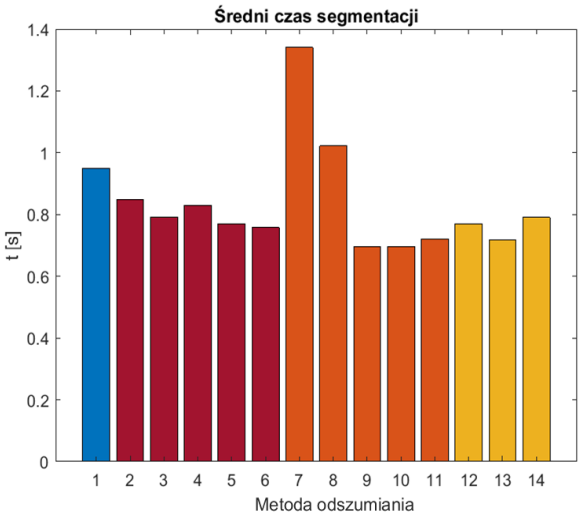


Przykładowe rezultaty segmentacji dla bazy OCTID

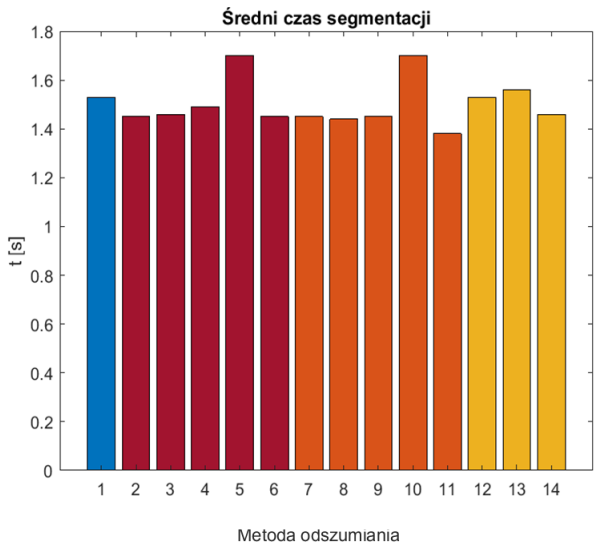


Ocena jakości segmentacji – czasochłonność segmentacji

CAVRI-A

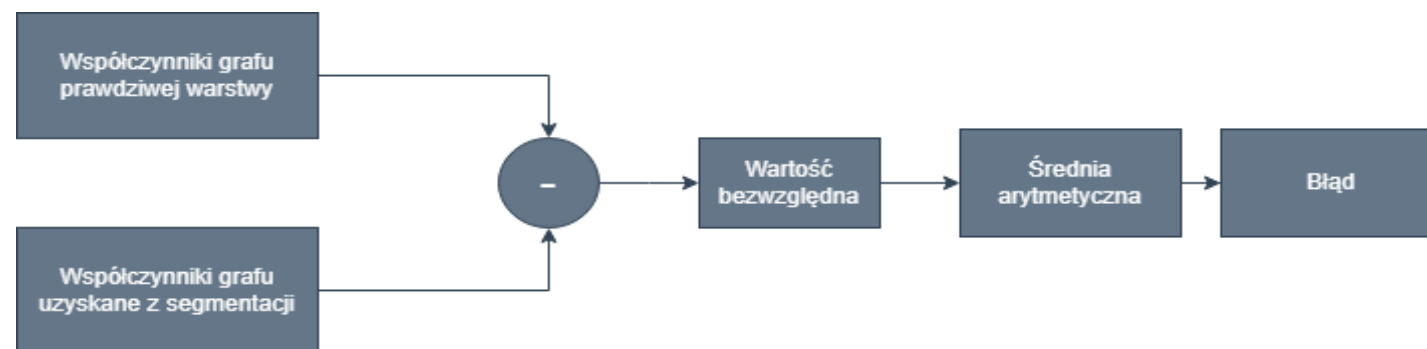
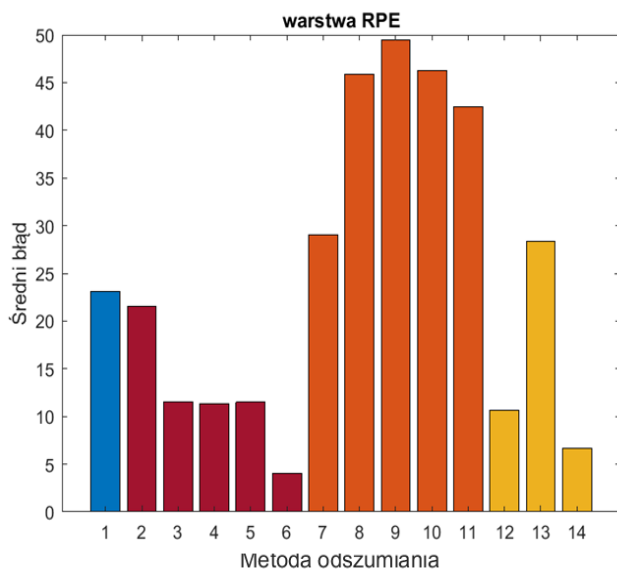
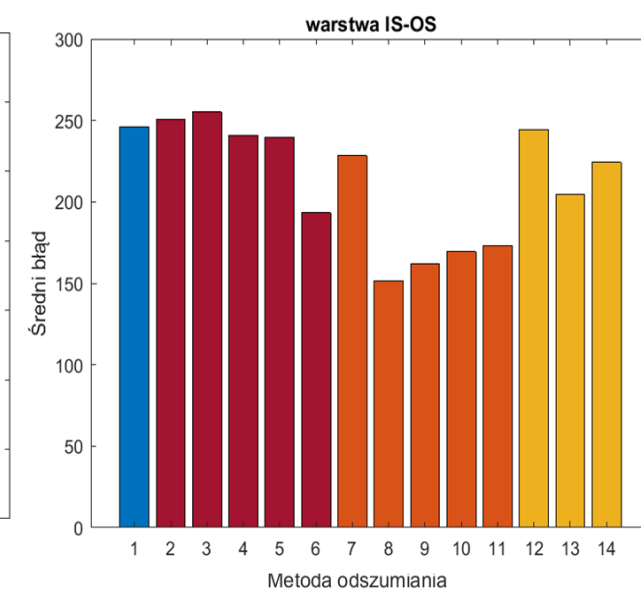
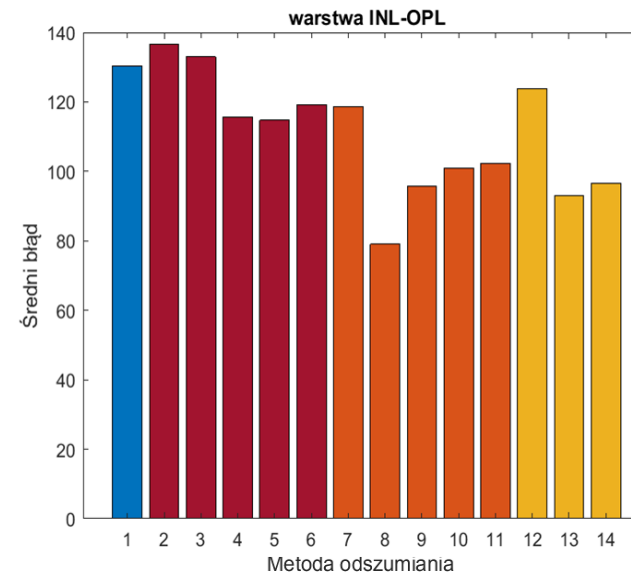
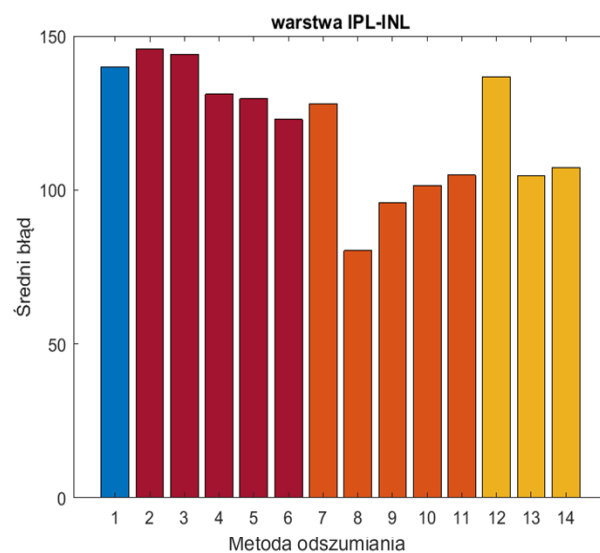



OCTID



L.p.	Nazwa metody	Procent przesegmentowanych obrazów z bazy CAVR-A[%]	Procent przesegmentowanych obrazów z bazy OCTID [%]
1	Bez odszumiania	97.62	100
2	Filtr uśr. n =3	97.84	100
3	Filtr uśr. n =5	98.17	100
4	Filtr uśr. n =7	94.47	100
5	Filtr uśr. n =9	98.37	100
6	Filtr uśr. n =11	77.74	100
7	Filtr med. n=3	89.76	100
8	Filtr med. n=5	84.79	100
9	Filtr med. n=7	87.48	100
10	Filtr med. n=9	90.74	94.74
11	Filtr med. n=11	92.85	100
12	Sieć DnCNN	98.09	100
13	Sieć FFDNet	85.02	100
14	Sieć ADNet	88.09	100

Ocena jakości segmentacji – poprawność segmentacji



Podsumowanie

- Rozwiązania wykorzystujące sieci neuronowe do odsumiania obrazów, pozwoliły na uzyskanie większych wartości wskaźników PSNR oraz SSIM, niż filtry medianowe i uśredniające.
- Odszumianie z wykorzystaniem sieci neuronowych zajęło średnio wielokrotnie więcej czasu niż odsumianie metodami tradycyjnymi.
- Zastosowanie filtracji pozwoliło, dla większości przeprowadzonych eksperymentów, skrócić średni czas segmentacji w porównaniu do B-skanów niepoddanych procesowi odsumiania.
- Dla warstw ILM, IPL-INL, INL-OPL oraz IS-OS najniższe średnie wartości błędów segmentacji uzyskano dla filtrów medianowych, najwyższe dla filtrów uśredniających. Dla warstwy RPE odwrotnie. Dla sieci neuronowych wyniki uzyskano dla sieci FFDNet, najgorsze dla DnCNN. Dla warstwy RPE najlepsze wyniki dla sieci ADNet, najgorsze FFDNet.
- Zastosowanie odpowiedniej metody filtracji pozwala na uzyskanie mniejszych błędów segmentacji, w porównaniu do obrazów niepoddawanych filtracji.
- Najwyższe wartości PSNR i SSIM, uzyskiwane dla odsumiania z sieciami neuronowymi, nie przełożyły się na najlepsze wyniki jakości segmentacji.